

选题	2024 年第十四届 APMCM 亚太地区大学生数学建模竞赛（中文赛项）	参赛编号
B		apmcm24102462

洪水灾害预测模型的设计与分析

摘要

洪水作为常见且破坏力极强的自然灾害，不仅由自然因素驱动，人为活动也极大地影响其频率和严重程度。本文从不同指标特征分析视角出发，根据机器学习算法建立不同等级预警评价模型、洪水发生概率预测模型，实现对洪水发生的准确预测与分析。

针对问题 1，建立决策树回归模型与 XGBoost 回归模型，以洪水发生概率为结果变量与 20 个指标（连续变量）进行关联性分析；为确保得出的关键指标在不同模型中均表现显著，选择结合两个模型的结果得出最终预测并列举出具有强关联性与弱关联性的两组指标；结合实际因素分析指标相关程度密切的可能原因，并针对洪水的提前预防提出了合理的建议和措施。

针对问题 2，首先通过肘部法则（Elbow Method）得到最优簇数结果为 3，验证了洪水高、中、低三个等级事件分类的合理性和科学性；然后通过 K-means 聚类分析方法（K=3）成功将洪水发生概率数据分类；利用随机森林回归模型建立了洪水预警评价模型，将聚类成功完成后的三类数据分三次输入至模型中，得出最合适的关联指标及其权重值。最后，根据得出的数据针对模型灵敏度进行分析，为后续进一步的特征分析、概率预测等提供了可靠依据。

针对问题 3，选择多层感知机（MLP）算法建立洪水发生概率预测模型，基于问题 1 的分析结果将具有强关联性的指标作为预测模型所需数据并进行预处理确保数据的完整性和一致性；通过数据准备、模型训练以及模型推理三个阶段成功建立并得到了具有高拟合度和稳定性的预测模型；基于特征重要性分析选定 5 个关键指标，在原模型的基础上采用调整网络结构、正则化技术、网格搜索调整学习率的方式进行模型优化，成功提高了模型拟合度，并且结果具有良好的可解释性与合理性。

针对问题 4，基于问题 3 中建立的预测模型对附件 test.csv 所有事件发生洪水的概率进行预测并将结果填入 submit.csv 中（具体结果见支撑材料）；将预测结果通过频率分布直方图和折线图进行可视化，通过直观观察、Shapiro-Wilk 统计的方法验证了模型预测结果符合正态分布特性，具有较高的泛化能力和实用性。

综上所述，洪水灾害预测模型的设计与建立提高了洪水发生概率的预测精度，为防洪预警和应对提供了科学依据，并且对洪水灾害的预防和管理具有重要的现实意义。

关键词：决策树 XGBoost 随机森林 K-means 多层感知机 Shapiro-Wilk

目录

一、问题重述.....	1
1.1 问题背景.....	1
1.2 问题要求.....	1
二、问题分析.....	1
2.1 总体分析.....	1
2.2 问题 1 的分析.....	2
2.3 问题 2 的分析.....	2
2.4 问题 3 的分析.....	2
2.5 问题 4 的分析.....	2
三、符号说明.....	3
四、问题 1 模型的建立与求解.....	3
4.1 洪水发生概率与不同指标的相关程度分析.....	3
4.1.1 基于决策树回归模型的建立与求解.....	3
4.1.2 基于 XGBoost 回归模型的建立与求解.....	5
4.1.3 针对决策树回归模型与 XGBoost 回归模型的综合分析.....	7
4.2 指标相关性的原因分析.....	8
4.3 提前预防的合理建议与措施.....	8
五、问题 2 模型的建立与求解.....	8
5.1 不同等级洪水事件的分类及分析.....	8
5.2 随机森林回归预警评价模型的建立与求解.....	9
六、问题 3 模型的建立与求解.....	11
6.1 数据预处理.....	11
6.2 基于神经网络的洪水发生概率预测模型建立与求解.....	12
6.2.1 单层感知机模型.....	12
6.2.2 MLP 模型的建立与求解.....	12
6.2.3 MLP 模型结果分析.....	14
6.3 关键指标下的模型调整与优化.....	15
七、问题 4 的求解.....	17
7.1 洪水发生概率的数据预测.....	17
7.2 预测结果的可视化与分析.....	17
八、模型的评价及推广.....	18
参考文献.....	19
附 录.....	20

一、问题重述

1.1 问题背景

洪水作为最常见、破坏力最强的自然灾害之一，常由暴雨、急剧融冰化雪、风暴潮等自然因素引起，不仅威胁到人类生命安全，还对农业、基础设施、生态环境等造成严重破坏。然而，洪水的发生不仅由自然因素驱动，人为活动也极大地影响其频率和严重程度，例如，迅猛的人口增长、耕地扩展、围湖造田以及乱砍滥伐等活动都会改变地表状态和汇流条件，从而加剧洪水灾害的发生和影响^[1]。

因此，识别影响洪水发生的关键因素并准确预测洪水发生的概率，不仅能提高防洪预警的准确性和及时性，同时有效减少了洪水灾害带来的损失。

1.2 问题要求

问题设置循序渐进，全面系统地从数据分析到模型构建，再到实际预测和结果分析，逐步提高对洪水灾害的预测能力。每个问题既相互独立，又紧密关联，共同服务于整体目标——如何在复杂的自然因素和人为因素影响下，对洪水的发生概率做出准确预测。

问题 1 首先要求根据附件 `train.csv` 中提供的数据，分析并可视化影响洪水发生概率的 20 个不同指标，确定并分别列举出每个指标与洪水发生的相关性强弱，通过不同指标因素推断可能的原因，针对洪水的提前预防提出合理的建议和措施。

问题 2 首先要求将附件 `train.csv` 中的洪水发生概率进行分类，给出高、中、低三种不同风险的洪水事件更具关联性的指标特征，在此基础上，选择合适的指标并计算权重值，建立不同风险等级的洪水预警评价模型，并对模型进行灵敏度评估。

问题 3 要求利用问题 1 中指标分析结果建立洪水发生概率的预测模型，从 20 个指标中选取合适的指标预测洪水发生的概率并验证模型的准确性；在此基础上，探究选择 5 个指标时如何调整并改进预测模型。

问题 4 要求利用问题 3 中建立的洪水发生概率预测模型，对附件 `test.csv` 中所有事件发生洪水的概率进行预测，并将预测结果填入附件 `submit.csv` 中；绘制发生洪水概率的直方图和折线图并验证预测结果的分布是否符合正态分布。

二、问题分析

2.1 总体分析

本题是一个关于洪水发生事件指标数据分析与概率预测的问题。

分析目的上，需要对附件数据进行分析，确定 20 个不同指标与洪水发生概率的关联程度，对影响洪水发生的因素与概率做出初步判断。因此，本题需要达成三个主要任务：其一，根据洪水发生的概率对洪水事件进行分类，确定高、中、低三种风险事件不同的指标特征。通过计算不同指标的权重建立不同风险等级的洪水预警评价模型，并对模型进行灵敏度分析；其二，基于前述的分析结果，建立洪水发生概率的预测模型并选取合适的指标预测洪水发生的概率。在仅使用 5 个关键指标的情况下，对预测模型调整和改进；其三，对附件 `test.csv` 中所有事件发生洪水的概率进行预测，并绘制出概率直方图和折线图以验证结果是否服从正态分布，确保模型的泛化能力和稳健性。

数据特征上，关于洪水灾害的数据具有多维度、异质性强、噪声较多等特征。因此，本题数据相对复杂特殊，需要对数据进行预处理，以提高模型的准确性和稳定性。

模型选择上，由于洪水数据样本量大，并考虑到问题的背景、目的等与实际应用密

切相关，所选模型应当追求合理性、实际性，以便于结果的解读和应用。




图 1 总体分析示意图

2.2 问题 1 的分析

问题 1 的核心目的是在于确定哪些指标与洪水事件的发生密切相关，为后续预测洪水发生概率提供依据。通过对附件 `train.csv` 中的数据进行分析和可视化，得出 20 个指标中的关键影响因素。但是，由于数据中可能存在噪声、异常值等，传统的简单模型已不足以揭示这些关系。因此，可以采用机器学习方法来分析指标与洪水发生的关系趋势，并用统计量或可视化工具来刻画这些趋势。基于这些分析结果，提出合理的洪水预防建议和措施，以降低洪水带来的风险和损失。

2.3 问题 2 的分析

问题 2 的核心目的在于根据洪水发生的概率通过聚类算法（K-means 聚类、层次聚类等）将附件 `train.csv` 中的洪水事件分为三类，并利用特征重要性分析或相关性分析的方法指明不同等级洪水事件的密切相关指标。基于选定的关键指标和其权重建立不同风险等级的预警评价模型并进行模型的灵敏度分析，确定对预测结果影响最大的指标，并根据分析结果调整模型结构和参数，以提高模型的稳定性和可靠性。

2.4 问题 3 的分析

问题 3 的核心目的在于选择合适的机器学习方法建立洪水发生概率的预测模型。在 20 个指标中选取合适的指标完成模型准确性的验证及性能的评估，并基于特征重要性分析选定 5 个关键指标，在关键指标下优化和改进模型，确保在减少特征数量的情况下，模型仍能保持较高的预测性能。

2.5 问题 4 的分析

问题 4 的核心目的在于进一步验证模型的有效性，其一预测附件 `test.csv` 中的所有事件发生洪水的概率，评估模型在未见数据上的表现，确保模型不仅在训练数据上有效，在新的数据环境中同样具有预测能力；其二绘制概率直方图和折线图，检验结果是否服从正态分布以反映模型预测结果的合理性和数据的自然变异性。

三、符号说明

符号	含义
y_i	均方误差 (MSE) 的实际值, $i = 1,2$
$\hat{y}_i$	均方误差 (MSE) 的预测值, $i = 1,2$
n_i	均方误差 (MSE) 子节点的样本数量, $i = 1,2$
Ω	正则化项
γ, λ	正则化参数
η	学习率
w	权重
f_j	回归模型中的特征
x_i	欧氏距离中的数据点
σ	激活函数
β_i	动量项的衰减系数, $i = 1,2$

四、问题 1 模型的建立与求解

4.1 洪水发生概率与不同指标的相关程度分析

4.1.1 基于决策树回归模型的建立与求解

洪水发生概率及 20 个不同指标均为连续变量, 考虑以洪水发生概率为结果变量, 与各个指标进行回归分析。

首先, 利用决策树回归模型评估每个指标对洪水发生概率的关联程度, 通过构建树形结构进行分割以实现预测目标变量。决策树^[2]是一种基于树形结构的监督学习方法, 用于处理分类和回归问题, 如图 2 所示。它通过递归地将数据集划分为更小的子集, 形成一棵树状结构。每个内部节点表示一个特征, 每个分支表示该特征的一个可能取值, 每个叶节点表示一个类标签或一个连续值。根据特征的取值从根节点开始逐步向下遍历树, 最终达到叶节点以确定数据的分类或预测值。针对问题 1, 由于洪水发生概率存在多个特征影响, 因此, 选用决策树回归建立模型。




图 2 决策树回归模型

建立决策树回归模型的过程如下:

构建树形结构: 决策树由根节点、内部节点和叶节点组成。根节点包含整个数据集，每个内部节点根据某个特征进行分裂，叶节点包含最终的预测值。模型不断分裂节点，逐步缩小数据集的范围，以提高预测的精确度。

初始化: 从根节点开始，初始化整个数据集作为根节点的数据。根节点的预测值设为整个数据集的洪水发生概率的平均值，以此作为初始预测值。值得注意的是，平均值的设定有助于提供一个合理的基线预测，使得初始误差较小，从而提高模型的收敛速度和稳定性。

递归分裂: 在每个节点，选择最佳的特征和分裂点，根据分裂准则将数据集分成两个子节点。其中，分裂准则采用均方误差（MSE）或基尼指数。

MSE 具体公式如下所示：

$$MSE = \frac{1}{n_1} \sum_{i=1}^{n_1} (y_i - \hat{y}_1)^2 + \frac{1}{n_2} \sum_{i=1}^{n_2} (y_i - \hat{y}_2)^2 \quad (1)$$

其中， n_1 和 n_2 分别是两个子节点的样本数量， y_i 是实际值， $\hat{y}_1$ 和 $\hat{y}_2$ 是两个子节点的预测值。选择使得 MSE 最小的特征和分裂点进行分裂，从而优化洪水发生概率的预测。

基尼指数具体公式如下所示：

$$Gini(D) = 1 - \sum_{i=1}^n p_i^2 \quad (2)$$

其中， p_i 是样本点属于第 i 的概率。基尼指数衡量的是节点的不纯度，基尼指数越小，节点纯度越高。

选择森林覆盖率作为分裂特征，通过计算分裂后的 MSE，确定最佳的分裂点，如公式（3）所示：

$$\text{最佳分裂点} = \underset{s}{\operatorname{argmin}} (MSE = \frac{1}{n_1} \sum_{i=1}^{n_1} (y_i - \hat{y}_1)^2 + \frac{1}{n_2} \sum_{i=1}^{n_2} (y_i - \hat{y}_2)^2) \quad (3)$$

其中， s 表示分裂点。

树的生长: 决策树通过递归分裂节点生长，每次分裂都会根据当前节点的数据集选择最佳的特征和分裂点，直到满足停止条件。停止条件可以是树的最大深度、叶节点的最小样本数或 MSE 的阈值。例如，当某个特征（如侵蚀等）对洪水发生概率有显著影响时，模型会优先选择该特征进行分裂，以提高预测准确性。

训练完成，输入特征变量进行预测。首先，遍历树形结构，从根节点开始，根据输入数据的特征值，沿着决策树的分裂路径向下遍历，直到到达叶节点。当输入一个新的样本，该样本具有淤积、城市化水平、地形排水特征等，模型将沿着决策树的路径进行分裂，最终到达对应的叶节点。最终，叶节点的值即为输入数据的预测值。

最终，利用 cross-validation 评估模型的性能，防止过拟合；通过特征重要性分析（公式（4））识别对洪水发生概率影响指标排序。得到最终结果如图 3 所示。

$$Importance(f_j) = \sum_{t=1}^T I(f_j, t) \quad (4)$$

其中， $Importance(f_j)$ 表示特征 f_j 在所有树中的重要性， $I(f_j, t)$ 表示特征 f_j 在第 t 棵树中的重要性。通过分析特征重要性，识别出不同指标对洪水发生概率的预测关联程度。




图3 决策树回归模型求解结果

4.1.2 基于 XGBoost 回归模型的建立与求解

为了更有效的评估每个指标对洪水发生概率的影响，同时利用 XGBoost 回归模型进行分析。XGBoost (Extreme Gradient Boosting) 模型^[3]是基于决策树的集成学习方法，通过组合多棵决策树来提高模型的预测性能，如图4所示。




图4 XGBoost 回归模型

XGBoost 回归模型的目标是最小化以下目标函数，如公式（5）所示：

$$L(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (5)$$

其中， y_i 是实际的洪水发生概率， $\hat{y}_i$ 是模型预测的洪水发生概率， l 是损失函数， Ω 是正则化项， n 是样本数， K 是树的数量。

对于洪水发生概率预测，使用 MSE 作为损失函数，如公式（6）所示：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (6)$$

利用正则化项（公式（7））控制模型的复杂度以防止过拟合，包括树的复杂度和叶节点权重：

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (7)$$

其中， T 是树的叶节点数量， w_j 是第 j 个叶节点的权重， γ 、 λ 是正则化参数。

XGBoost 通过迭代构建树的方式进行训练，每次迭代时，模型会根据当前残差来生成新的树，从而逐步减少误差。在洪水发生概率预测的过程中，每次迭代都会基于之前的预测误差，调整模型参数以改进预测结果。

详细模型建立与训练过程如下：

初始化模型参数：设置初始的预测值为洪水发生概率的平均值。其中，平均值代表了数据的中心趋势，使模型在初始阶段具有较低的预测误差，有助于模型更快地收敛到最优解，增强了梯度下降算法的有效性，并提高训练效率。

计算梯度和 Hessian 矩阵：对于每个样本，计算损失函数的一阶导数和二阶导数，即梯度和 Hessian 矩阵（公式（8）-（9））从而在洪水发生概率的预测过程中，由此更新模型参数以不断减少预测误差。

$$\nabla L(\theta) = \left(\frac{\partial L}{\partial \theta_1}, \frac{\partial L}{\partial \theta_2}, \dots, \frac{\partial L}{\partial \theta_n} \right) \quad (8)$$

$$H(\theta) = \begin{bmatrix} \frac{\partial^2 L}{\partial \theta_1^2} & \frac{\partial^2 L}{\partial \theta_1 \partial \theta_2} & \dots & \frac{\partial^2 L}{\partial \theta_1 \partial \theta_n} \\ \frac{\partial^2 L}{\partial \theta_2 \partial \theta_1} & \frac{\partial^2 L}{\partial \theta_2^2} & \dots & \frac{\partial^2 L}{\partial \theta_2 \partial \theta_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 L}{\partial \theta_n \partial \theta_1} & \frac{\partial^2 L}{\partial \theta_n \partial \theta_2} & \dots & \frac{\partial^2 L}{\partial \theta_n^2} \end{bmatrix} \quad (9)$$

生成新的决策树：根据计算出的梯度和 Hessian 矩阵，生成新的决策树以拟合当前的洪水发生概率预测误差。新的决策树通过最小化以下目标函数进行训练，如公式（10）所示：

$$L(q) = \sum_{j=1}^T [G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2] + \gamma T \quad (10)$$

其中， G_j 和 H_j 分别是叶节点 j 的梯度和 Hessian 矩阵的总和， w_j 是叶节点的权重， q 是决策树的结构， T 是叶节点的数量。

更新模型参数：根据新生成的决策树，更新模型的预测值（公式（11））。

$$\hat{y}_i^{(t+1)} = \hat{y}_i^{(t)} + \eta f_k(x_i) \quad (11)$$

其中， η 是学习率， f_k 是第 k 棵树的模型。通过每次迭代更新预测值，逐步减少洪水发生概率的预测误差。

迭代训练：重复计算梯度和 Hessian 矩阵、生成新的决策树以及更新模型参数这三个步骤，直到损失函数收敛或达到最大迭代次数。每次迭代都会生成一棵新的决策树，逐步提升模型的预测能力，从而更准确地预测洪水发生概率。

模型验证：使用交叉验证（cross-validation）评估模型性能，防止过拟合。cross-validation 将数据集分成多个子集，在不同子集上训练和验证模型，从而获得更稳定和可靠的性能评估。通过计算 MSE 和决定系数（ R^2 ）（公式（12））来衡量模型的预测准确性：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (12)$$

其中， $\bar{y}$ 是实际洪水发生概率的均值。

特征重要性分析：训练结束，通过特征重要性分析识别对洪水发生概率影响的指标排序。

值得注意的是，基于 XGBoost 模型对洪水发生概率进行预测后，进一步使用 SHAP (SHapley Additive exPlanations) 值 (图 5) 量化每个特征对预测结果的相关性，提供全局和局部的解释，从而更准确地解释每个特征对洪水发生概率预测的影响，增强模型的解释性和透明度。




图 5 SHAP 原理图示

特别地，SHAP 值基于博弈论中的 Shapley 值，为每个特征分配一个归一化数值，表示该特征对预测结果的影响，确保了每个特征的关联值总和等于模型预测值与基线预测值的差异，从而提供了一致的解释框架。其计算公式如下所示：

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! \cdot (|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)] \quad (13)$$

其中， ϕ_i 表示特征 i 的 SHAP 值， N 是所有特征的集合， S 是特征的子集， $f(S)$ 是只包含特征子集 S 时的模型预测值， $f(S \cup \{i\})$ 是包含特征子集 S 和特征 i 时的模型预测值。

完成上述步骤后，得到最终结果如图 6 所示。




图 6 XGBoost 回归模型求解结果

4.1.3 针对决策树回归模型与 XGBoost 回归模型的综合分析

在前两节中，分别使用了决策树回归模型和 XGBoost 回归模型对洪水发生概率进行了预测分析。最终结合两个模型的预测结果，确保得出的关键指标在不同模型中均表现显著，从而提供更加全面且可信的洪水预测依据。两个模型得出的结果具有一致性，经过分析得到弱相关性的结果有 5 个，分别为人口得分、气候变化、排水系统、河流管

理和海岸脆弱性，其余 15 个指标均为强相关性。

4.2 指标相关性的原因分析

针对相关性强的指标（侵蚀、大坝质量、地形排水等）而言，它们对洪水的发生概率有直接且显著的影响。比如侵蚀和地形排水条件决定了地表水的吸收和流动情况；大坝质量和基础设施的状况直接关系到防洪能力的有效性；季风强度会带来大量降雨，迅速增加地表径流量，这些因素都会显著增加洪水发生的概率。

相对而言，人口得分、气候变化、排水系统、河流管理和海岸脆弱性这些指标与洪水发生的直接相关性较弱。虽然这些因素在一定程度上影响洪水风险，但它们更多地影响洪水的后果和长期风险。比如，气候变化的短期效应难以精确量化；人口得分和气候变化虽然对环境和气候有长期影响，但短期内对洪水发生的直接影响有限。

因此，通过对强弱相关性指标的分析，实现了更加清晰地理解洪水发生的主要驱动因素和次要因素。

4.3 提前预防的合理建议与措施

基于以上指标相关性分析，提出以下合理的提前预防措施：

针对强相关性指标，例如增强季风强度监测和预报，提高地形排水能力，以及定期检查和维护大坝等关键基础设施，确保其在极端天气条件下的稳定性和可靠性。此外，加强侵蚀防治措施，防止土壤流失，也是降低洪水风险的重要手段。

针对弱相关性指标，同样需要采取相应措施以提高整体防洪能力。例如，改善排水系统和河流管理，提高城市和农村地区的排水效率和抗洪能力；通过政策和规划减少人口密集区的洪水风险，特别是在气候变化加剧的背景下，加强对气候变化的长期研究和监测。通过综合运用这些措施，实现有效提高洪水预防和应对能力，减少洪水灾害对人类社会的影响。

五、问题 2 模型的建立与求解

5.1 不同等级洪水事件的分类及分析

为界定不同等级的洪水事件，首先将附件 train.csv 中洪水发生的概率通过频率分布直方图表示，如图 7 所示。由图可知，大部分洪水数据分布在概率数值为 0.5 附近。为进一步明确等级界限，利用肘部法则 (Elbow Method) 评估不同簇数下聚类模型的表现，绘制了 SSE 与簇数关系图，通过观察图中的拐点得出最优簇数为 3，如图 8 所示。该值正好对应题中的高、中、低三个事件等级，进一步验证了洪水事件三分类的合理性和科学性，为后续的特征分析和预警模型的建立提供了基础。




图 7 洪水概率的频率分布直方图




图 8 肘部法则确定最优簇数图

由上述分析后，利用 K-means 算法^[4]对洪水数据进行聚类，分为高、中、低三种不同等级。该算法作为一种迭代聚类算法，将数据分割成 k 个簇，使得同一簇内的数据点彼此之间更加相似，更加有效地将不同风险等级的事件进行区分。

针对 K-means 算法，具体实现步骤如下：

随机选择 k 个初始聚类中心 $\{\mu_1, \mu_2, \dots, \mu_k\}$ ，本题 k=3，分别表示高风险、中风险和低风险三类。

将每个数据点分配到最近的聚类中心，依据欧氏距离计算公式（公式（14））：

$$d(x_i, \mu_j) = \sqrt{\sum_{m=1}^n (x_{im} - \mu_{jm})^2} \quad (14)$$

其中， $d(x_i, \mu_j)$ 表示数据点 x_i 到聚类中心 μ_j 的距离， n 为数据的维度。对于洪水发生概率数据，该步骤将每个事件分配到对应的风险等级。

重新计算每个簇的聚类中心，将其更新为该簇内所有数据点的平均值（公式（15））。

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i \quad (15)$$

其中， μ_j 是第 j 个聚类中心， C_j 是第 j 个簇的数据点集合， $|C_j|$ 是该簇中数据点的数量。更新聚类中心能够使每次迭代后聚类中心更准确地代表簇内数据点的中心位置。

重复迭代分配数据点、更新聚类中心两步骤多次，直到聚类中心不再发生变化或达到最大迭代次数，确保聚类结果的稳定性和准确性。

经过上述步骤，最终成功将附件 train.csv 中洪水发生的概率聚类成不同类别，得到三个簇，每簇对应一种风险等级（高、中、低），如图 9 所示。




图 9 洪水概率聚类分析结果

5.2 随机森林回归预警评价模型的建立与求解

利用随机森林^[5]回归模型（图（10））建立预警评价模型实现预测洪水发生的风险等级。将上一节聚类成功完成后的三类数据分三次输入至预警评价模型中，得出最合适的关联指标及其权重值。




图 10 随机森林模型

对于预警评价模型，详细模型建立与训练过程如下：

首先进行数据标准化，对所有特征进行标准化处理，使其均值为 0，标准差为 1，以确保模型训练的稳定性和准确性。

随机抽样：在相同类别的洪水数据中随机抽取多个子样本，每个子样本用于训练一棵决策树。假设原始数据集有 n 个样本，每个子样本的大小也是 n ，通过有放回抽样的方法形成不同的子样本集。

决策树构建：对每个子样本构建一棵决策树。在每个节点上，随机选择 m 个特征（通常为总特征数的平方根），并在这些特征中选择最佳分裂特征和分裂点，以最大化信息增益（公式（16））或最小化均方误差（MSE）。

$$\text{Gain}(S, A) = \text{Entropy}(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \text{Entropy}(S_v) \quad (16)$$

其中， $\text{Entropy}(S)$ 是集合 S 的熵， $\text{Values}(A)$ 是特征 A 的所有可能取值， S_v 是特征 A 取值为 v 的子集。

所有决策树构建完成后，通过集成这些树的预测结果来进行回归预测。具体来说，对每棵树的预测结果取平均值（公式（17））。

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}_t \quad (17)$$

其中， $\hat{y}$ 是最终的预测值， $\hat{y}_t$ 是第 t 棵树的预测结果， T 是决策树的总数。

通过初始划分出的测试数据对模型进行评估，并计算模型的 MSE 和 R^2 。最后通过对模型的特征重要性分析包括特征重要性得分以及特征重要性总和归一化（公式（18）-（19）），得出对洪水风险预测影响最大的几项指标。

$$\text{Importance}(f_j) = \frac{1}{T} \sum_{t=1}^T (\text{MSE}_{\text{before}} - \text{MSE}_{\text{after}}) \quad (18)$$

其中， $\text{Importance}(f_j)$ 表示特征 f 在所有树中的重要性得分， $\text{MSE}_{\text{before}}$ 是分裂前的 MSE， $\text{MSE}_{\text{after}}$ 是分裂后的 MSE。

$$w_j = \frac{\text{Importance}(f_j)}{\sum_{i=1}^n \text{Importance}(f_i)} \quad (19)$$

其中， w_j 是特征 f_j 的归一化权重， n 是特征的总数。

由上述步骤，有效建立了洪水不同风险等级的预警评价模型，根据模型进行特征重要性分析与权重计算，验证模型对于不同指标的灵敏度。最终结果如表 1 所示。

表 1 不同等级洪水事件相应指标特征及权重值

特征名称	高风险	特征名称	中风险	特征名称	低风险
地形排水	14.20%	地形排水	14.10%	大坝质量	13.40%
淤积	12.30%	无效防灾	13.40%	基础设施恶化	10.80%
农业实践	11.50%	农业实践	8.90%	滑坡	10.30%
河流管理	8.80%	气候变化	6.40%	河流管理	9.10%
人口得分	7.80%	规划不足	6.30%	气候变化	8.40%
滑坡	7.30%	城市化	5.30%	城市化	7.80%
湿地损失	7.00%	基础设施恶化	5.30%	人口得分	7.20%
无效防灾	5.80%	侵蚀	5.20%	森林砍伐	5.70%
政策因素	4.90%	流域	5.00%	淤积	4.90%
气候变化	4.50%	湿地损失	5.00%	湿地损失	4.60%
大坝质量	3.40%	大坝质量	4.20%	季风强度	4.30%
城市化	3.30%	排水系统	3.80%	侵蚀	3.80%
规划不足	2.60%	人口得分	3.60%	海岸脆弱性	3.30%
流域	1.70%	滑坡	3.10%	规划不足	2.70%
季风强度	1.50%	政策因素	3.00%	地形排水	1.10%
森林砍伐	1.30%	河流管理	2.80%	政策因素	1.10%
排水系统	1.00%	淤积	1.90%	排水系统	0.80%
基础设施恶化	1.00%	季风强度	0.90%	流域	0.80%
侵蚀	0.00%	森林砍伐	0.90%	农业实践	0.00%
海岸脆弱性	0.00%	海岸脆弱性	0.90%	无效防灾	0.00%

由表 1 可知，具有高、中、低风险的洪水事件都具有相应的指标特征，对于高风险洪水事件最能够影响其发生的指标及其权重依次分别为：地形排水（14.20%）、淤积（12.30%）、农业实践（11.50%）、河流管理（8.80%）、人口得分（7.80%）等；对于中风险洪水事件最能够影响其发生的指标及其权重依次分别为：地形排水（14.10%）、无效防灾（13.40%）、农业实践（8.90%）、气候变化（6.40%）、规划不足（6.30%）等；对于低风险洪水事件最能够影响其发生的指标及其权重依次分别为：大坝质量（13.40%）、基础设施恶化（10.80%）、滑坡（10.30%）、河流管理（9.10%）、气候变化（8.40%）等；

此外，通过模型灵敏度分析，验证模型的稳健性，确保在不同情境下模型仍然具有可靠的预测性能。同样地，结合表 1 数据得到针对 20 个指标对模型的灵敏度影响。

六、问题 3 模型的建立与求解

6.1 数据预处理

基于问题 1 的分析结果确定对于洪水发生概率具有强关联性的相应指标作为所需建立预测模型的数据集。由于提供数据量较大，故需检查数据集是否存在缺失值以防止

预测模型出现训练误差。针对缺失数据处理方法为删除含有缺失值的样本、使用均值或中位数填充缺失值，以及使用插值法填补缺失值。

6.2 基于神经网络的洪水发生概率预测模型建立与求解

6.2.1 单层感知机模型

单层感知机作为神经网络模型（图 11），主要解决线性可分的分类问题，由一个输入层和输出层组成，能够对输入特征进行加权求和并通过激活函数产生输出。




图 11 单层感知机模型

输入层接受多维向量 $X = [x_1, x_2, \dots, x_n]$ ，每个输入特征 x_i 对应一个权重 w_i ，所有权重构成向量权重 $W = [w_1, w_2, \dots, w_n]$ ，偏置 b 用于调整决策边界的位置。

输出层计算加权和并通过激活函数生成输出： $y = \sigma(W \cdot X + b)$ ，其中， σ 是激活函数。常用的激活函数包括阶跃函数和线性函数。

利用 MSE 误差函数衡量模型预测值与实际值之间的差异 $e = y - \hat{y}$ ，并不断更新权重和偏置： $W = W - \eta e X$ ， $b = b - \eta e$ ；直至差小于预设阈值或达到最大迭代次数时停止训练。

然而，单层感知机表达能力有限无法捕捉复杂的模式和特征，比如非线性问题。因此，多层感知机（MLP）的引入实现处理更复杂的数据和关系。

6.2.2 MLP 模型的建立与求解

MLP 模型^[6]（图 12）作为深度学习方法，通过多层非线性变换捕捉复杂的特征关系，具有强大的非线性拟合能力，主要包括输入层、中间层（一个或多个隐藏层）、输出层。相比传统的线性模型，它能够更好地处理多维数据和非线性关系，针对题目中涉及的复杂多变的气象、地理、人口等洪水数据，该模型尤为合适。灵活性和可扩展性使其能够适应不同规模和复杂度的数据集，通过调整网络结构和参数实现最优预测性能。




图 12 MLP 感知机模型

模型建立的过程主要分为三个阶段：数据准备、模型训练以及模型推理。

(1) 数据准备阶段

将经过数据预处理后产生的数据作为输入特征输入模型。具体地，选定的指标特征包括侵蚀、基础设施恶化、季风强度、大坝质量、地形排水、淤积。

(2) 模型训练阶段

首先，数据按照 7:2:1 的比例划分为训练集、验证集和测试集，完成模型的训练；接下来，训练集数据依次进入模型的输入层、中间层、输出层；

模型中包含多个隐藏层，每个隐藏层由若干神经元组成，每个神经元与前一层的所有神经元全连接，使用非线性激活函数 ReLU(Rectified Linear Unit)以捕捉非线性关系。隐藏层的输出通过全连接层传递到下一层。

隐藏层定义如下所示：

$$H = \sigma(W_h \cdot X + b_h) \quad (20)$$

其中， H 是隐藏层输出， W_h 和 b_h 分别是隐藏层的权重和偏置， σ 是激活函数。

ReLU 激活函数定义如下所示：

$$\sigma(z) = \max(0, z) \quad (21)$$

其中， z 是输入值。ReLU 函数能够有效缓解梯度消失问题。

输出层由一个神经元组成，使用 sigmoid 激活函数将输出值限制在 0 到 1 之间，表示洪水发生的概率。

输出层定义如下所示：

$$Output = \sigma(W_o \cdot X + b_o) \quad (22)$$

其中， $Output$ 是最终预测值， W_o 和 b_o 分别是输出层的权重和偏置。

sigmoid 激活函数定义如下所示：

$$\sigma(z) = \frac{1}{1+e^{-z}} \quad (23)$$

其中， z 是输入值。Sigmoid 函数将输出值映射到(0, 1)区间，适合概率输出。

因此，MLP 模型的公式如下所示：

$$Output = \sigma(W_o \cdot \sigma(W_{h2} \cdot \sigma(W_{h1} \cdot X + b_{h1}) + b_{h2}) + b_o) \quad (24)$$

模型训练过程中，使用 MSE 作为损失函数，定义如下所示：

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_t)^2 \quad (25)$$

使用 Adam 优化器进行梯度下降，更新模型参数。此外，结合动量和自适应学习率调整进行优化。

Adam 优化器参数更新如公式 (26) - (30) 所示：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} L(\theta) \quad (26)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} L(\theta))^2 \quad (27)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (28)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (29)$$

$$\theta = \theta - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}} \quad (30)$$

其中， η 是学习率， β_1 和 β_2 是动量项的衰减系数， ϵ 是防止除零的一个极小值。

训练过程中，为防止模型在训练集上表现良好但在验证集和测试集上表现较差的过

拟合问题，采用早停技术（early stopping），即在每个训练迭代周期结束时，监控模型在验证集上的损失函数值。如果在若干迭代周期内验证集损失值没有显著下降或开始上升，则提前停止训练，并恢复到验证集损失值最小的模型参数。不仅防止过拟合，提高模型的泛化能力，而且节省训练时间，确保了模型在实际应用中的预测准确性和可靠性。

（3）数据推理阶段

模型训练完成后，在测试集上计算 MSE（公式（6））和 R^2 （公式（12））评估其性能，确保模型能够准确预测洪水的发生概率。

R^2 表示模型解释自变量总变异的比例，其值越接近 1，表示模型对洪水发生变异解释能力越强，预测效果越好。

$R^2 \approx 1$ 表示模型能很好地解释洪水发生的概率，性能较好；

$0 < R^2 < 0.5$ 表示模型对洪水发生概率的解释能力较弱，性能较差；

$R^2 \approx 0$ 表示模型几乎不能解释洪水发生的变异，性能较差；

MSE 衡量了预测值与实际值之间的平均平方误差。值越小，表示模型的预测误差越小，性能越好。

性能评估完成后，利用交叉验证调整模型超参数以选择最佳参数组合。不断调整后验证模型最终预测性能。

6.2.3 MLP 模型结果分析

完成 MLP 模型的建立、训练和推理后，对其在测试集上的表现进行详细评估和分析。针对基于问题 1 分析结果训练的预测模型，得出结果，如图 13-14 所示。




图 13 MLP 模型 MSE 结果

由图 13 显示了训练和验证的 MSE 随迭代次数（Epochs）的变化情况。训练 MSE 在最初几次迭代中迅速下降，随后趋于稳定，验证 MSE 则在前面几个 Epoch 内波动较大，但最终与训练 MSE 接近，且趋于平稳。表明模型在学习过程中成功拟合了训练数据，同时在验证数据上也具有良好的泛化能力，未出现明显的过拟合现象。




图 14 MLP 模型拟合结果

为进一步验证模型的预测性能和稳定性，由图 14 显示，预测值与真实值之间高度重合，表明模型在大多数情况下能够准确预测洪水发生的概率。结合图 13 可以得出模型在训练和验证阶段都表现良好，且在实际测试中保持了良好的预测性能，未出现明显的过拟合或欠拟合现象。模型的高拟合度和稳定性使其适用于洪水发生概率的预测。

6.3 关键指标下的模型调整与优化

根据问题 1 得到的 15 个指标，选择前 5 个作为关键指标特征（地形排水、大坝质量、季风强度、基础设施恶化、侵蚀）用于训练改进后的模型。

为了与调优后的模型有效对比，在原模型的基础上实现进行拟合验证，如图 15 所示。




图 15 调优前的 MLP 模型拟合结果

由图 15 可以看出，模型预测值（橙色）在整体上较为集中，呈现出较为均匀的分布，主要集中在 0.4 到 0.6 之间；而实际值（蓝色）则表现出更大的波动范围，从 0.3 到 0.7 不等。尽管存在一些偏差，但总体上，模型的预测值与实际值有较好的重合度，表明模型在大多数情况下能够准确预测洪水发生的概率。然而，某些区域的实际值与预测值仍有显著差异，模型需要进一步优化。

因此，在上述建立的 MLP 模型的基础上改进模型，实现减少特征后仍能保持预测性能不变，主要从以下几个方面进行调整和优化：

调整网络结构

隐藏层数量和神经元数量：根据减少后的特征数量，减少隐藏层的数量和每层神经元的数量，以避免模型过于复杂。

正则化技术

在隐藏层中添加 Dropout 层，随机丢弃部分神经元，以增强模型的泛化能力。具体公式如下所示：

$$h_i = \begin{cases} \frac{h_i}{1-p} & \text{if } h_i \text{ is retained} \\ 0 & \text{if } h_i \text{ is dropped} \end{cases} \quad (31)$$

其中， h_i 是第 i 个神经元的输出， p 是 Dropout 的保留概率。

在损失函数中添加 L2 正则化项，以防止权重过大导致过拟合。具体公式如下所示：

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m \theta_j^2 \quad (32)$$

其中， $L(\theta)$ 是损失函数， n 是样本数量， λ 是正则化强度超参数， θ_j 是模型参数， m 是参数数量。

超参数调优

学习率调整：通过网格搜索的方法，调整学习率以平衡训练速度和稳定性。

Batch 大小调整：根据数据量和模型复杂度，调整 Batch 大小以优化训练效率和模型性能。

完成以上调优后，观察拟合度评估模型性能，如图 16 所示。




图 16 调优后的 MLP 模型拟合结果

由图 16 显示调优后的预测值和实际值更加紧密重合，表明模型在大多数情况下的预测准确度有所提高。尽管特征数量从 15 个减少到 5 个，模型的简化并没有显著影响其性能，这得益于对关键特征的优化选择和模型结构的调整。然而，由于特征数量减少，某些复杂因素可能未被完全捕捉，导致在部分区域仍存在一定的偏差。总体而言，调优后的模型在简化特征集的情况下，依然保持了较高的预测精度，证明了优化策略的有效性。

七、问题 4 的求解

7.1 洪水发生概率的数据预测

基于问题 3 中建立的洪水发生概率预测模型，预测附件 test.csv 中所有事件发生洪水的概率。首先对需预测数据进行与训练数据相同的预处理过程，处理后将测试数据输入至预测模型，得到每个事件的洪水发生概率并将结果保存到附件 submit.csv（见附录）。

7.2 预测结果的可视化与分析

针对已经预测出的数据进行可视化得到概率直方图和折线图，如图 17-18 所示。




图 17 洪水概率的频率分布直方图




图 18 洪水概率的频率分布折线图

由图 17 显示了直方图的形式下的洪水发生概率的频率分布，频率分布呈现中心聚拢，并向两侧逐渐减少，峰值位于 0.50 附近，数据呈钟形分布。

由图 18 显示了折线图的形式下的洪水发生概率的频率分布，分布范围大致在 0.35 到 0.70 之间，同样地，峰值也出现在 0.50 左右，频率最高，呈现出一个大致对称的钟形分布。

通过直观观察两个图像，它们都符合正态分布的基本形态特征。此外，分布的均值接近 0.50，标准差适中，进一步验证了其接近正态分布的结论。

为了更准确地判断数据是否服从正态分布，选择 Shapiro-Wilk 统计（公式（33））进行检验，得到结论： p 值 >0.05 ，则可以认为数据服从正态分布。

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (33)$$

其中， $x_{(i)}$ 表示第 i 个排序的样本值， $\bar{x}$ 表示样本均值， a_i 表示权重系数，由样本大小 n 决定。

综合上述方法，得出洪水发生概率的分布服从正态分布。

八、模型的评价及推广

模型优点

1、采用决策树回归和 XGBoost 回归模型，实现高效处理复杂数据。决策树回归模型通过树形结构特征，捕捉复杂交互作用；XGBoost 回归模型通过集成多棵弱学习树并使用梯度提升方法，有效减小误差，提高洪水发生概率预测的准确性。

2、结合不同模型得出预测结果，确保关键指标在不同模型中均表现显著，使得结果具有较强的可信性。

3、通过树形结构和特征重要性分析，实现清晰地看到各个特征对预测结果的贡献，从而帮助理解模型的决策过程，便于用户信任和采用。

模型缺点

1、由于考虑的变量较多，模型中可能存在多重共线性问题，从而影响模型的稳定性和预测精度。

2、对于需要实时更新和处理的数据，现有模型可能需要频繁地重新训练，导致计算成本增加。

模型推广

1、文中的回归模型还可推广应用于其他自然灾害预测领域，如地震、台风等。

2、将文中的模型与大数据处理平台相结合，提高数据处理和模型训练的效率，利用分布式计算技术，实现对海量数据的实时分析和预测。

参考文献

- [1]杨丹.区域洪水灾害风险特征及其演化态势分析[D].东北农业大学,2023.
- [2]Costa, V.G., Pedreira, C.E. Recent advances in decision trees: an updated survey. *Artif Intell Rev* 56,4765–4800,2023.
- [3]Chen, T., Guestrin, C. XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*,785–794,2016.
- [4]王森,刘琛,邢帅杰.K-means 聚类算法研究综述[J].*华东交通大学学报*, 39(05):119-126,2022.
- [5]Parmar, A., Katariya, R., Patel, V. A Review on Random Forest: An Ensemble Classifier. *International Conference on Intelligent Data Communication Technologies and Internet of Things (ICICI)*,26:758-763,2018.
- [6]张荣,李伟平,莫同 深度学习研究综述[J].*信息与控制*, 47(4):385-397,2018.

附 录

支撑材料:

1. 代码:

 问题1: Q1.ipynb

 问题2: Q2.py

 问题3: Q3.py

 问题4: Q4.py

 模型优化: 优化.py

 绘制正态分布: 正太.py

2. 提交数据:

 submit.csv